Рецензія на публікацію «DeepOP: A Hybrid Framework for MITRE ATT&CK Sequence Prediction via Deep Learning and Ontology»

1. Вступ

Рецензована стаття (Zhang, Xue, Su, Electronics 2025, 14, 257) присвячена проблемі прогнозування багатокрокових атак типу APT (Advanced Persistent Threat) в умовах IIoT. Традиційні системи виявлення та запобігання вторгнень не здатні ефективно протидіяти складним, розподіленим у часі атакам, тому автори пропонують перейти від реактивної детекції до проактивного прогнозування поведінки зловмисника. Основна мета дослідження - розробити гібридний фреймворк DeepOP, який поєднує глибоке навчання та онтологічне міркування для стандартизованого та дрібнозернистого передбачення наступних технік ATT&CK на основі реальних послідовностей атак.

2. Методологія

Автори використовують комплексний підхід. Спершу вони збирають дані з відкритих джерел кіберзагроз (CTI): 1500 експертно анотованих звітів та ~2200 оригінальних звітів APT-кампаній (2006–2024). Для вилучення технік ATT&CK перенавчають модель rcATT, розширюючи покриття до понад 200 технік. Далі розробляють онтологію COASE та набір правил SWRL для встановлення причинно-наслідкових зв’язків і паралельних шляхів між техніками, що дозволяє автоматично формувати послідовності атак. Для прогнозування запропоновано архітектуру Transformer з механізмом причинного віконного самоуваження (CWA), який захоплює локальні та глобальні залежності. Експерименти проведено на GPU RTX 4080; використано метрики accuracy, precision, recall, F1-міру, а також досліджено стійкість до пропусків у вхідних даних (0–60%).

3. Результати

Запропонована модель DeepOP продемонструвала найкращі результати порівняно з LSTM, GRU, байєсівською мережею та оригінальним Transformer: F1-міра 0,894 проти 0,865 (LSTM) та 0,861 (Transformer). При збільшенні кроку прогнозування (J=6) перевага DeepOP стає суттєвішою (F1=0,767 проти 0,647 у LSTM). В умовах високого відсотка пропусків (60%) модель зберігає F1=0,526, тоді як інші підходи падають до 0,272–0,452. Кейс-стаді на реальному звіті Frankenstein підтвердив, що онтологічний модуль успішно виділяє кілька паралельних шляхів атаки, чого не роблять існуючі методи.

4. Ключові інсайти

1. Онтологічне міркування для побудови набору даних - автори не просто сортують техніки за тактиками, а встановлюють причинно-наслідкові зв’язки. Для мене це важливо, оскільки дозволяє уникнути хибних уявлень про лінійність APT-атак і краще моделювати паралельні гілки.
2. Механізм CWA з лінійною складністю - на відміну від стандартного самоуваження $O(N^2)$, CWA забезпечує $O(N)$ завдяки вікнам. Це корисно для практичних систем прогнозування в реальному часі з обмеженими обчислювальними ресурсами.
3. Стійкість до пропусків даних - DeepOP значно менше деградує при відмовах систем виявлення. Для мене це сигнал, що модель можна інтегрувати в умовах недосконалих IDS, що часто трапляється в промислових мережах.

5. Висновок

Стаття робить вагомий внесок у галузь: розроблено онтологію COASE, створено датасет із причинними зв’язками та паралельними шляхами, запропоновано ефективний механізм CWA.

Результати переконливо демонструють перевагу DeepOP у багатокроковому прогнозуванні та стійкості до шумів. Перспективними напрямами майбутніх досліджень автори називають розширення набору даних, інтеграцію потокових даних для онлайн-прогнозування та адаптацію до динамічних доменів.