Рев'ю наукової публікації
"ІМПЛЕМЕНТАЦІЯ ІНТЕЛЕКТУАЛЬНОЇ СИСТЕМИ АНАЛІЗУ ТОНАЛЬНОСТІ ТА КЛАСТЕРИЗАЦІЇ ПУБЛІКАЦІЙ У СОЦІАЛЬНІЙ МЕРЕЖІ TWITTER"

1. Вступ
Стаття авторів Т. Батюка та Д. Досина, опублікована в журналі "Innovative Technologies and Scientific Solutions for Industries" (2023, №1), присвячена актуальній проблемі аналізу тональності текстових повідомлень у соціальній мережі Twitter. Основне дослідницьке питання полягає в оптимізації процесу аналізу тональності та кластеризації публікацій шляхом використання комбінації нейронної мережі LSTM (Long Short-Term Memory) та алгоритму кластеризації k-means. Метою дослідження є створення інтелектуальної системи, яка забезпечує більш ефективний (на 10-15%) аналіз тональності порівняно з традиційними підходами, що використовують згорткові нейронні мережі (CNN) та ієрархічну кластеризацію.

2. Методологія
Автори використовують комплексний підхід до аналізу текстових даних, що включає:
- Архітектуру системи, що базується на діаграмах варіантів використання, діяльності та потоків даних, які демонструють логіку завантаження, обробки, аналізу та візуалізації даних.
- Нейронну мережу LSTM з архітектурою, що включає три основні проходи (забування, вхідний та вихідний), які забезпечують ефективне запам'ятовування довготривалих залежностей у текстових послідовностях. Мережа навчається на 2000 твітах за 500 епох з розміром партії 20 елементів.
- Алгоритм кластеризації k-means з використанням "ліктьового" методу для визначення оптимальної кількості кластерів (в експерименті обрано три кластери). Алгоритм демонструє складність $O(n \cdot k \cdot m)$ проти $O(n^2 \log n)$ ієрархічної кластеризації.
- Попередню обробку даних, що включає видалення хеш-тегів, URL-посилань, спеціальних символів, приведення до нижнього регістру, стематизацію та перевірку орфографії.

3. Результати
Експериментальне дослідження проведено на датасеті з 2000 твітів англійською мовою за ключовими словами "Ukraine", "war", "missile", "offensive" та "invasion" за період з липня 2022 року.
Ключові результати включають:
- Аналіз тональності показав, що більшість повідомлень мають нейтральний характер, при цьому позитивні коментарі демонструють вищий рівень емоційності (до 0.8) порівняно з негативними (до 0.2), що свідчить про більш емоційну реакцію на позитивні новини під час війни.
- Кластеризація за допомогою k-means дозволила розділити текстові екземпляри на три кластери (негативний, нейтральний, позитивний), що візуалізовано за допомогою PCA, TSNE та 3D-графіків.
- Порівняльний аналіз ефективності показав, що запропонована комбінація LSTM + k-means працює на 10-15% швидше та ефективніше за CNN + ієрархічну кластеризацію, особливо на великих датасетах.

4. Ключові інсайти
Інсайт 1: Ефективність LSTM для коротких текстів
Автори переконливо демонструють, що LSTM є оптимальним вибором для аналізу коротких текстів (до 280 символів у Twitter) завдяки здатності зберігати довготривалі залежності через механізм комірок пам'яті та трьох проходів. Для мене це важливо, оскільки в сучасних NLP-

задачах часто доводиться працювати саме з короткими повідомленнями, де контекст відіграє критичну роль, а традиційні підходи (CNN) втрачають ефективність через обмеження висоти вектора.
Інсайт 2: Переваги k-means над ієрархічною кластеризацією
Аргументація авторів щодо вибору k-means є надзвичайно переконливою: лінійна складність $O(n \cdot k \cdot m)$ проти квадратичної $O(n^2 \log n)$, можливість ітеративного перерахунку центрів кластерів та гнучкість у виборі кількості кластерів через "ліктьовий" метод. Цей інсайт є цінним, оскільки в реальних проектах часто виникає потреба в швидкій кластеризації великих обсягів даних, де традиційні методи стають непрактичними.
Інсайт 3: Архітектурна гнучкість системи
Діаграми варіантів використання та потоків даних демонструють продуману модульну архітектуру, де кожен компонент (завантаження даних, препроцесинг, LSTM-аналіз, кластеризація, візуалізація) є незалежним і може бути модифікований без впливу на інші. Це дозволяє адаптувати систему для різних мов, ключових слів та типів даних. Для моєї роботи це важливо, оскільки забезпечує можливість масштабування та налаштування системи під конкретні бізнес-завдання.

5. Висновок
Стаття є вагомим внеском у галузь аналізу соціальних медіа, пропонуючи практичне рішення для автоматизованого аналізу тональності та кластеризації публікацій. Основні досягнення включають:
1. Обґрунтування переваг LSTM та k-means над традиційними підходами для коротких текстів.
2. Розробку повноцінної інтелектуальної системи з чіткою архітектурою та модульною структурою.
3. Експериментальне підтвердження ефективності системи на реальних даних з Twitter.

Потенційні напрями майбутніх досліджень включають: адаптацію системи для багатомовних датасетів, інтеграцію з іншими соціальними мережами (Facebook, Instagram), використання трансформерних моделей (BERT, GPT) для покращення точності аналізу тональності, а також застосування системи в реальному часі для моніторингу громадської думки.