

Рев'ю на публікацію: "Огляд методів аналізу даних та методів машинного навчання при прогнозуванні ішемічної хвороби серця"

1. Вступ

У статті авторів О.Д. Земляного та О.Г. Байбуз, опублікованій у 2022-2023 роках, представлено систематичний огляд 40 досліджень, присвячених застосуванню методів інтелектуального аналізу даних та машинного навчання (ML) для прогнозування ішемічної хвороби серця (ІХС). Основною метою роботи є узагальнення сучасних підходів до прогнозування ІХС, визначення найефективніших алгоритмів, наборів даних та програмних інструментів, а також виявлення прогалин у цій галузі для майбутніх досліджень.

2. Методологія

Для пошуку літератури використовувалася пошукова система Semantic Scholar. Автори відібрали 40 досліджень за період 2014-2022 років, зосередившись на роботах, які описують застосування ML для прогнозування, виявлення або діагностики ІХС. У рамках огляду розглянуто такі ключові компоненти: доступні набори даних, методи попередньої обробки (робота з пропущеними даними, викидами, незбалансованістю класів тощо), найпоширеніші алгоритми ML (SVM, дерева рішень, нейронні мережі, ансамблеві методи), метрики оцінки (Accuracy, Precision, Recall, F1, Specificity) та використовуване програмне забезпечення.

3. Результати

Огляд показав, що найчастіше використовуваними алгоритмами є метод опорних векторів (SVM) – 70%, дерева рішень (DT) – 68% та наївний байєсів класифікатор (NB) – 65%. Ансамблеві методи застосовувались у 55% робіт. Найпопулярнішим набором даних виявився Cleveland (303 записи). Найвищу загальну точність (Accuracy) продемонстрували алгоритми: на наборі Statlog – глибока нейронна мережа (DNN) – 98,15%, а на наборі Cleveland – ансамблевий метод BO-SVM – 93,3%. Водночас, автори відзначають недостатнє використання сучасних ансамблевих методів (XGBoost) та навчання з підкріпленням (RL). Більшість досліджень базуються на відкритих датасетах, а не на первинних клінічних даних.

4. Ключові інсайти (для власної роботи)

Критична важливість попередньої обробки даних: Автори детально описують проблеми (пропуски, викиди, незбалансованість, масштабування) та методи їх вирішення. Я усвідомив, що без якісної підготовки даних навіть найкращий алгоритм дасть незадовільний результат. Для мене це чіткий алгоритм дій на початку будь-якого ML-проєкту: спочатку аналіз та очищення даних, а потім вибір моделі.

Ефективність ансамблевих методів: Огляд чітко демонструє, що ансамблеві алгоритми (BO-SVM, AdaBoost, XGBoost) стабільно показують вищу точність (до 93-98%) порівняно з окремими класифікаторами. Візьму це за правило: при розробці власної моделі прогнозування варто починати з простих алгоритмів, але обов'язково тестувати ансамблі для досягнення найкращого результату.

Обмеження відкритих датасетів та метрики AUC: Автори вказують, що більшість досліджень використовують невеликі відкриті набори даних (наприклад, Cleveland на 303 записи), що може призводити до упередженості. Крім того, рідко використовується метрика AUC, яка є більш об'єктивною. Для себе роблю висновок: при можливості варто працювати з реальними

клінічними даними, а якість моделі обов'язково оцінювати за допомогою AUC, а не лише Accuracy.

5. Висновок

Цей огляд є цінним джерелом для дослідників у сфері медичної діагностики. Його головний внесок – систематизація знань про застосування ML для прогнозування ІХС, визначення найефективніших алгоритмів (LR, NN, SVM, бустінги) та програмних середовищ (Python, R перевершують спеціалізовані інструменти на кшталт WEKA). Автори окреслюють перспективні напрями для майбутніх досліджень: використання глибоких нейронних мереж, ансамблевих методів (XGBoost), навчання з підкріпленням, а також роботу з більшими вибірками первинних клінічних даних. Це довідник для планування власних експериментів.